大數據結構化程式設計
期末報告

學號 : 4111036012
姓名 : 張凱綾

資料集講解（特徵介紹）

資料集： xAPI-Edu-Data，主要記錄學生在中等教育階段的表現與背景資料。

部分主要特徵：

- Gender: Male/Female
- NationalITy
- PlaceofBirth
- GradeID
- SectionID
- Topic: English/ Math/...
- Semester
- Relation: 是否父母為學校員工
- Raisedhands: 參與程度
- VisITedResources
- Discussion:
- ParentAnsweringSurvey
- ParentschoolSatisfaction
- StudentAbsenceDays
- Class: High/Middle/Low
- StageID: lowerlevel/MiddleSchool/HighSchool

資料前處理
(資料摘要)

```python
# 1. 匯入套件
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix, accuracy_score

# 2. 讀取資料
df = pd.read_csv('xAPI-Edu-Data.csv')

# 3. 檢查資料
print(df.info())
print(df.duplicated().sum())
print(df.isnull().sum())
```

共480筆資料

沒有缺失值

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 480 entries, 0 to 479
Data columns (total 17 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   gender                    480 non-null    object
 1   NationalITy               480 non-null    object
 2   PlaceofBirth              480 non-null    object
 3   StageID                   480 non-null    object
 4   GradeID                   480 non-null    object
 5   SectionID                 480 non-null    object
 6   Topic                     480 non-null    object
 7   Semester                  480 non-null    object
 8   Relation                  480 non-null    object
 9   raisedhands               480 non-null    int64
 10  VisITedResources          480 non-null    int64
 11  AnnouncementsView         480 non-null    int64
 12  Discussion                480 non-null    int64
 13  ParentAnsweringSurvey     480 non-null    object
 14  ParentschoolSatisfaction  480 non-null    object
 15  StudentAbsenceDays        480 non-null    object
 16  Class                     480 non-null    object
dtypes: int64(4), object(13)
memory usage: 63.9+ KB
```

整數資料4筆，物件資料13筆

資料前處理

```python
# 1. 匯入套件
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix, accuracy_score

# 2. 讀取資料
df = pd.read_csv('xAPI-Edu-Data.csv')

# 3. 檢查資料
print(df.info())
print(df.duplicated().sum())
print(df.isnull().sum())
```

需要處理重複值

```
重複筆數： 2
缺失值總表：
 gender                    0
NationalITy                0
PlaceofBirth               0
StageID                    0
GradeID                    0
SectionID                  0
Topic                      0
Semester                   0
Relation                   0
raisedhands                0
VisITedResources           0
AnnouncementsView          0
Discussion                 0
ParentAnsweringSurvey      0
ParentschoolSatisfaction   0
StudentAbsenceDays         0
Class                      0
dtype: int64
```

無缺失值

資料前處理

```
df = df.drop_duplicates() #刪除所有重複列（保留第一次出現的）
```

```
重複筆數： 0
缺失值總表：
 gender                    0
NationalITy                0
PlaceofBirth               0
StageID                    0
GradeID                    0
SectionID                  0
Topic                      0
Semester                   0
Relation                   0
raisedhands                0
VisITedResources           0
AnnouncementsView          0
Discussion                 0
ParentAnsweringSurvey      0
ParentschoolSatisfaction   0
StudentAbsenceDays         0
Class                      0
dtype: int64
```

```
# 類別資料編碼，將每一類別對應到一個整數
le = LabelEncoder()
for col in df.select_dtypes(include='object').columns:
    df[col] = le.fit_transform(df[col])
```

特徵工程

- **相關係數分析：**

✓ 計算連續型特徵與目標變數（轉為數值）間的 Spearman 相關係數

✓ 發現 raisedhands, VisITedResources, Discussion 與成績正相關明顯

```
# 5. 顯示相關係數
plt.figure(figsize=(10, 8))
sns.heatmap(df.corr(), annot=True, cmap='coolwarm')
plt.title("Feature Correlation Matrix")
plt.show()
```

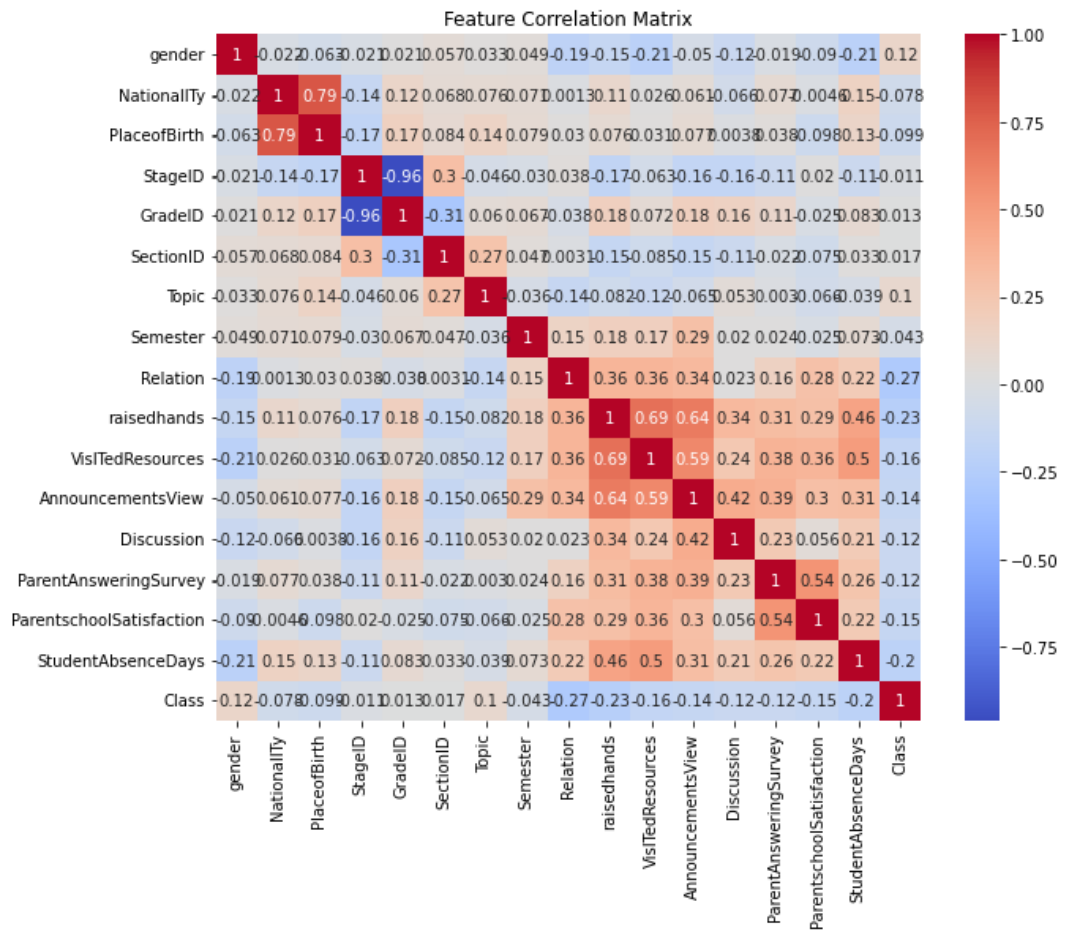

特徵工程

- **特徵分佈視覺化**：

✓ 使用直方圖與 boxplot 分析 raisedhands、Discussion 等變數

✓ 使用 sns.heatmap() 觀察相關矩陣

```
# 6.直方圖
plt.figure(figsize=(8, 5))
sns.histplot(data=df, x='raisedhands', hue='Class', kde=True, multiple='stack
plt.title("Raised Hands Distribution by Class")
plt.show()
```

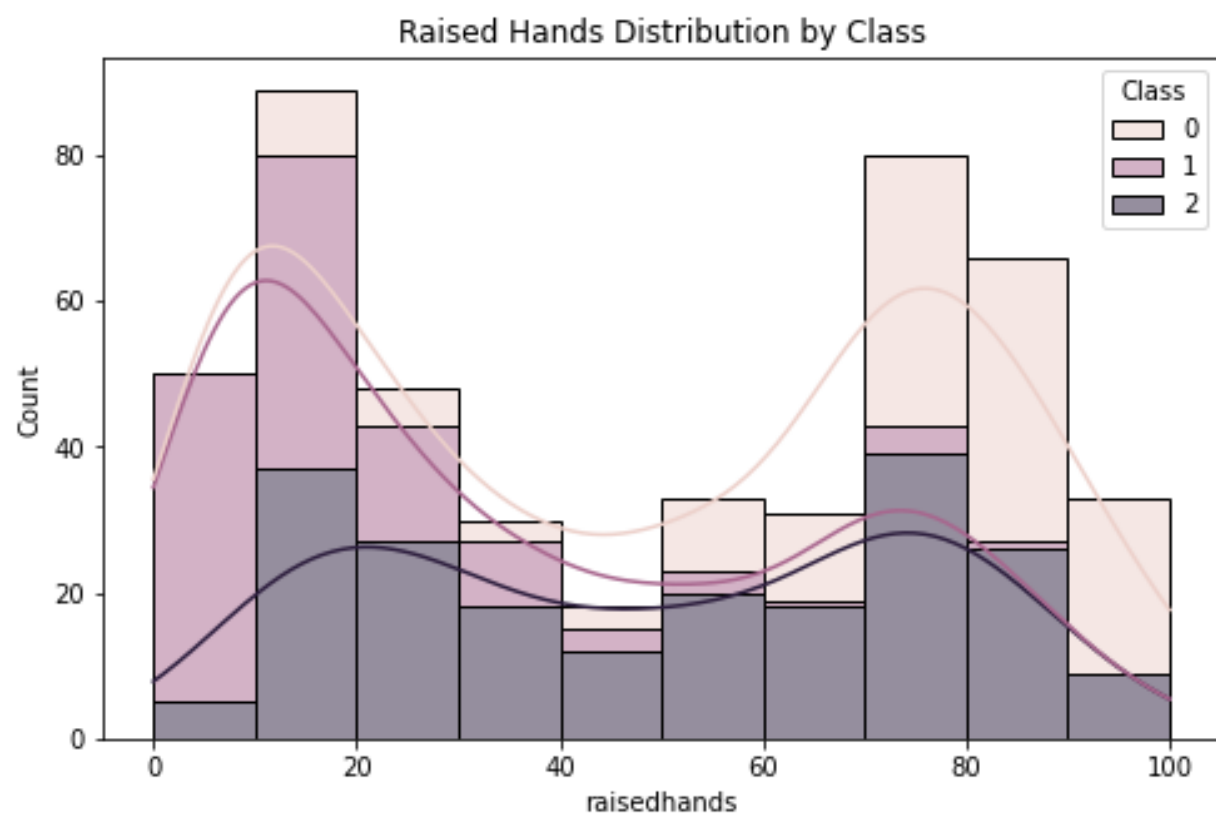

特徵工程

- **特徵分佈視覺化**：

✓ 使用直方圖與 boxplot 分析 raisedhands、Discussion 等變數

✓ 使用 sns.heatmap() 觀察相關矩陣

```
# 7.盒方圖
plt.figure(figsize=(8, 5))
sns.boxplot(x='Class', y='Discussion', data=df)
plt.title("Discussion Boxplot by Class")
plt.show()
```

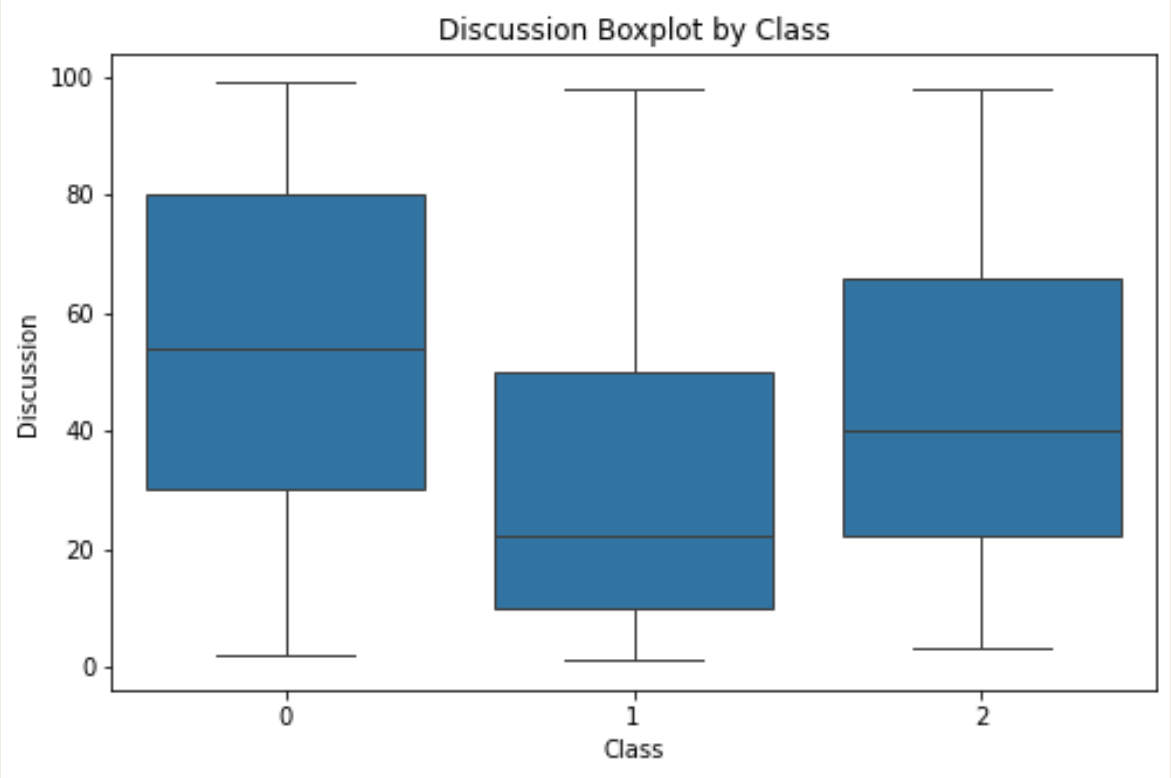

特徵工程

- **特徵分佈視覺化：**

✓ 使用直方圖與 boxplot 分析 raisedhands、Discussion 等變數

✓ 使用 sns.heatmap() 觀察相關矩陣

```
# 8.所有數值型特徵的直方圖
num_features = df.select_dtypes(include=['int64', 'float64']).columns
df[num_features].hist(bins=20, figsize=(12, 10))
plt.tight_layout()
plt.show()
```

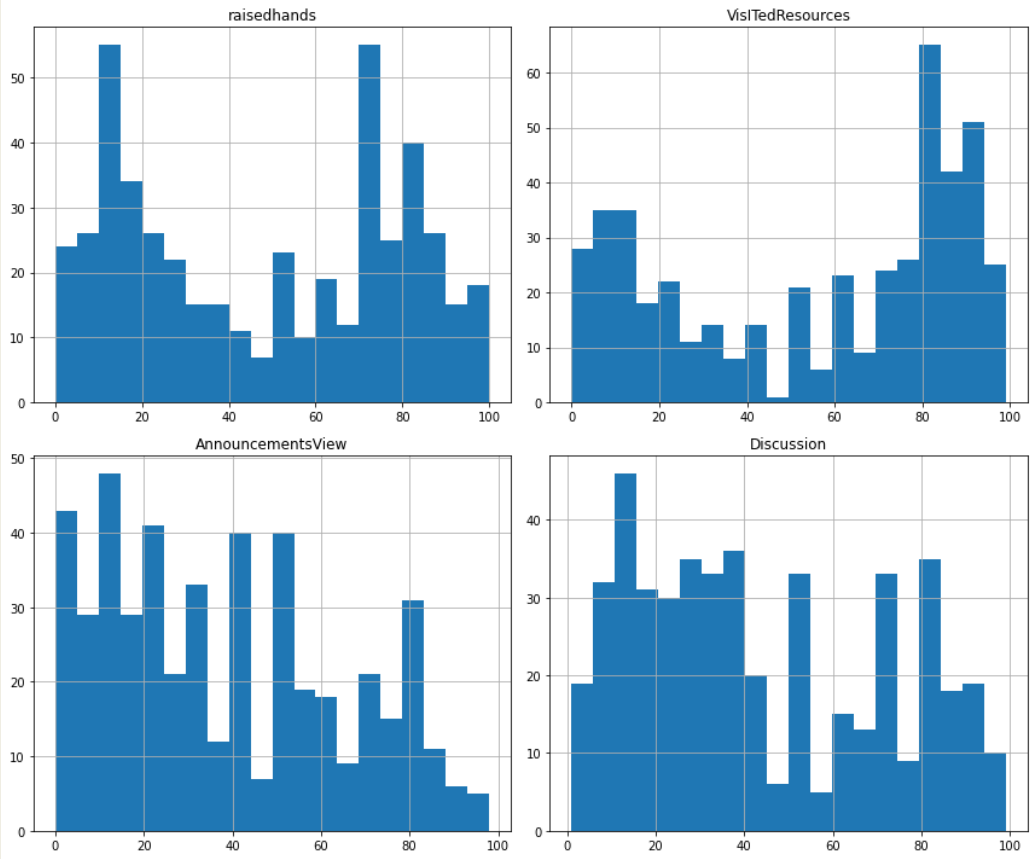

使用的模型

- Model1：Random Forest
- Model 2：K-Nearest Neighbors
- Model 3：Logistic Regression

透過交叉驗證選擇最佳參數，並比較各模型的預測效果。

```
# 11.模型訓練與預測
# (1) Random Forest
rf = RandomForestClassifier()
rf.fit(X_train, y_train)
y_pred_rf = rf.predict(X_test)

# (2) KNN
knn = KNeighborsClassifier()
knn.fit(X_train, y_train)
y_pred_knn = knn.predict(X_test)

# (3) Logistic Regression
lr = LogisticRegression(max_iter=1000)
lr.fit(X_train, y_train)
y_pred_lr = lr.predict(X_test)
```

分類結果與比較

使用訓練集 80%，測試集 20%

```python
# 9./標籤分離
X = df.drop('Class', axis=1)
y = df['Class']

# 10.切分資料集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

```python
# 12.評估函式
def evaluate(model_name, y_true, y_pred):
    print(f"=== {model_name} ===")
    print("Confusion Matrix:")
    print(confusion_matrix(y_true, y_pred))
    print("Classification Report:")
    print(classification_report(y_true, y_pred))
    print("Accuracy:", accuracy_score(y_true, y_pred))
    print("\n")

# 13.顯示結果
evaluate("Random Forest", y_test, y_pred_rf)
evaluate("KNN", y_test, y_pred_knn)
evaluate("Logistic Regression", y_test, y_pred_lr)
```

分類結果Random Forest

使用訓練集 80%，測試集 20%

```
=== Random Forest ===
Confusion Matrix:
[[19  0  5]
 [ 0 25  2]
 [ 6  3 36]]
Classification Report:
              precision    recall  f1-score   support

           0       0.76      0.79      0.78        24
           1       0.89      0.93      0.91        27
           2       0.84      0.80      0.82        45

    accuracy                           0.83        96
   macro avg       0.83      0.84      0.83        96
weighted avg       0.83      0.83      0.83        96

Accuracy: 0.8333333333333334
```

分類結果K-Nearest Neighbors

使用訓練集 80%，測試集 20%

```
=== KNN ===
Confusion Matrix:
[[15  0  9]
 [ 0 21  6]
 [10  5 30]]
Classification Report:
              precision    recall  f1-score   support

           0       0.60      0.62      0.61        24
           1       0.81      0.78      0.79        27
           2       0.67      0.67      0.67        45

    accuracy                           0.69        96
   macro avg       0.69      0.69      0.69        96
weighted avg       0.69      0.69      0.69        96

Accuracy: 0.6875
```

分類結果Logistic Regression

使用訓練集 80%，測試集 20%

```
=== Logistic Regression ===
Confusion Matrix:
[[21  0  3]
 [ 0 23  4]
 [ 6  4 35]]
Classification Report:
              precision    recall  f1-score   support

           0       0.78      0.88      0.82        24
           1       0.85      0.85      0.85        27
           2       0.83      0.78      0.80        45

    accuracy                           0.82        96
   macro avg       0.82      0.83      0.83        96
weighted avg       0.82      0.82      0.82        96

Accuracy: 0.8229166666666666
```

分類比較

使用訓練集 80%，測試集 20%

Model	Accuracy	Macro F1-score	Weighted F1-score
Random Forest	0.83	0.83	0.83
Logistic Regression	0.82	0.83	0.82
KNN	0.69	0.69	0.69

討論、總結與建議

- Raisedhands、Discussion 等互動性特徵與成績密切相關

→ 應積極鼓勵學生參與課堂活動

- 分類效果最好為 Random Forest

→具備良好的非線性處理能力

- 若能加入更多心理或家庭背景等特徵，模型或許能更精準

修課心得

一開始看到這個課程的名稱，因為它看似很複雜而感到有些害怕，怕自己無法負荷太難的程式課程。真正開始上課後，發現老師講得很仔細，會一步一步教我們怎麼做，也會提前提示我們會遇到的困難要怎麼解決，助教對於我不會的問題，不管是簡單或困難，都會有耐心地告訴我要如何去處理。更意外的是，上課內容非常充實豐富，真的感受到收穫累累，相信經過這樣的訓練，對我未來的職場優勢亦會有幫助的。